

Домашнее задание 1, Новиков Герман, 277

Задача 1. Пусть \hat{F}_n — эмпирическая функция распределения, построенная по простой выборке длины n , с неизвестной функцией распределения F .

- Какое распределение имеет случайная величина $n\hat{F}_n$?
- Используя оценку $\hat{F}_n(x)$ и вариант центральной предельной теоремы, построить приближенный (в виду предельности теоремы) интервал, содержащий значение $F(x)$ с заданной вероятностью α .

Решение:

- По определению:

$$n\hat{F}_n(x) = \sum_{i=1}^n I(X_i < x)$$

. Но тогда, для произвольного x : $n\hat{F}_n(x)$ есть сумма n независимых Бернуллевских случайных величин с $p = F(x)$, а следовательно

$$n\hat{F}_n(x) \sim \text{Bin}(n, F(x))$$

•

$$\begin{aligned} \sqrt{n}(\hat{F}_n(x) - F(x)) &= \left(\frac{\sum_{i=1}^n I(X_i < x) - nF(x)}{\sqrt{n}} \right) = \\ &= \left(\frac{\sum_{i=1}^n I(X_i < x) - n\mathbf{E}(I(X_1 < x))}{\sqrt{n}} \right) \xrightarrow{CLT} N(0, \mathbf{D}(I(X_1 < x))) \end{aligned}$$

Где $\mathbf{D}(I(X_1 < x)) = F(x)(1 - F(x))$

Таким образом, получаем асимптотическую оценку на распределение разности между эмперической и реальной функцией распределения, взвешенной на \sqrt{n} . Положим, что выборка достаточно большая и можно считать, что равенство не асимптотическое. Тогда мы просто берем двухсторонний квантиль:

$$x_{\frac{\alpha}{\sqrt{n}}}^{(1)} = G^{-1}\left(\frac{\alpha}{2\sqrt{n}}\right), x_{\frac{\alpha}{\sqrt{n}}}^{(2)} = G^{-1}\left(1 - \frac{\alpha}{2\sqrt{n}}\right)$$

Где $G(x)$ - та самая, полученная нами предельная функция распределения.

Теорема 1. (*Неравенство Дворецкого-Кифера-Вольфовитца*).

Пусть $X_1, \dots, X_n \sim F$. Тогда для любого $\varepsilon > 0$:

$$\mathbb{P}\left(\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \geq \varepsilon\right) \leq 2 \exp(-2n\varepsilon^2)$$

Задача 2. Построить на основании неравенства Дворецкого-Кифера-Вольфовитца неасимптотический вариант критерия согласия Колмогорова. Указать критическую область при заданном уровне значимости.

Решение: критерий согласия Колмогорова:

$$\mathbb{P}\left(\sqrt{n} \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \leq \varepsilon\right) = \mathbb{P}\left(\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \leq \frac{\varepsilon}{\sqrt{n}}\right) \leq 1 - 2 \exp(-2\varepsilon^2)$$

Задаём α - уровень значимости: $\sqrt{n} \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \geq t_\alpha$

В нашем случае $K(\varepsilon) = 1 - 2 \exp(-2\varepsilon^2)$

Хотим: $\alpha = 1 - K(\varepsilon)$, следовательно выбираем

$$t_\alpha = \varepsilon = K^{-1}(1 - \alpha) = \sqrt{\frac{\ln(2) - \ln(\alpha)}{2}}$$

Таким образом отвергаем гипотезу H_0 при:

$$\sqrt{n}D_n \geq \sqrt{\frac{\ln(2) - \ln(\alpha)}{2}}$$

Задача 3. Доказать, что

$$\sup_{x \in \mathbb{R}} |\hat{F}(x) - F(x)| \xrightarrow{a.e.} 0,$$

где предел берется по n - числу элементов выборки.

Доказательство(можно не комментировать, это доказательство из книги, свое я обещаю придумать): Пусть $F(x)$ непрерывна. Фиксируем $\varepsilon = 1/N$. Так как $\forall x F(x) \in [0, 1]$ и непрерывна, то существует набор чисел $\{x_i\}_{i=1}^N \subset \mathbb{R} \cup \{-\infty, +\infty\}$ такой, что на каждом из отрезков $[x_i, x_{i+1}]$ функция $F(x)$ растёт на $\frac{1}{N}$, где N - произвольное целое. Тогда $\forall x \in [x_i, x_{i+1}]$ выполнено:

$$\hat{F}(x) - F(x) \leq \hat{F}(x_{i+1}) - F(x_i) = \hat{F}(x_{i+1}) - F(x_{i+1}) + \varepsilon$$

$$\hat{F}(x) - F(x) \geq \hat{F}(x_i) - F(x_{i+1}) = \hat{F}(x_i) - F(x_i) - \varepsilon$$

Обозначим A_k - множество элементарных событий ω , на которых $\hat{F}(x_k) \rightarrow F(x_k)$. Мера этого множества $P(A_k) = 1$ в силу УЗБЧ. Но тогда $\forall \omega \in A = \cup_{k=0, N} A_k$ существует $n(\omega)$: что $\forall n \geq n(\omega)$ выполнено

$$|\hat{F}(x_k) - F(x_k)| < \varepsilon, k = 0, 1, \dots, N.$$

Но тогда вместе с предыдущим получаем требуемое утверждение:

$$\sup_z |\hat{F}(x) - F(x)| < 2\varepsilon.$$

Для произвольной функции аналогично. Только нужно более аккуратно поступать с разрывами.

Задача 4. Построить plug-in оценки для математического ожидания и дисперсии. Являются ли эти оценки несмещенными?

Решение:

- Для математического ожидания $\bar{x} = \hat{E}(X) = \frac{1}{n} \sum_{i=1}^n X_i$. Она является несмещенной, т.к. $E\hat{E}(X) = E\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n EX_i = EX$, где $X \sim F(x)$

- Для дисперсии: $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{x})^2$. Она не является несмещенной:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{x} + \bar{x}^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{x} \left(\frac{1}{n} \sum_{i=1}^n X_i \right) + \frac{1}{n} \sum_{i=1}^n \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{x}^2 = \overline{x^2} - \bar{x}^2$$

Тогда получим, что $ES^2 = E(\overline{x^2} - \bar{x}^2) = \dots = \sigma^2 - \frac{\sigma^2}{n} = \sigma^2(1 - \frac{1}{n})$. То есть не является несмещенной, однако просто нормируется до несмещенной, домножением на $\frac{n}{n-1}$.